Apprentissage automatique

Les algorithmes d'apprentissage automatique

Algorithme : K-Means clustering

https://www.javatpoint.com/k-means-clustering-algorithm-in-machine-learning

Introduction

- K-Means Clustering (Regroupement K-Moyennes) est un algorithme d'apprentissage **non supervisé**, qui regroupe l'ensemble de données non étiquetées en différents clusters.
- Le K définit le nombre de clusters (groupes) qui doivent être créés dans le processus de regroupement, pour K=2, il y aura deux clusters, et pour K=3, il y aura trois clusters, et ainsi de suite.

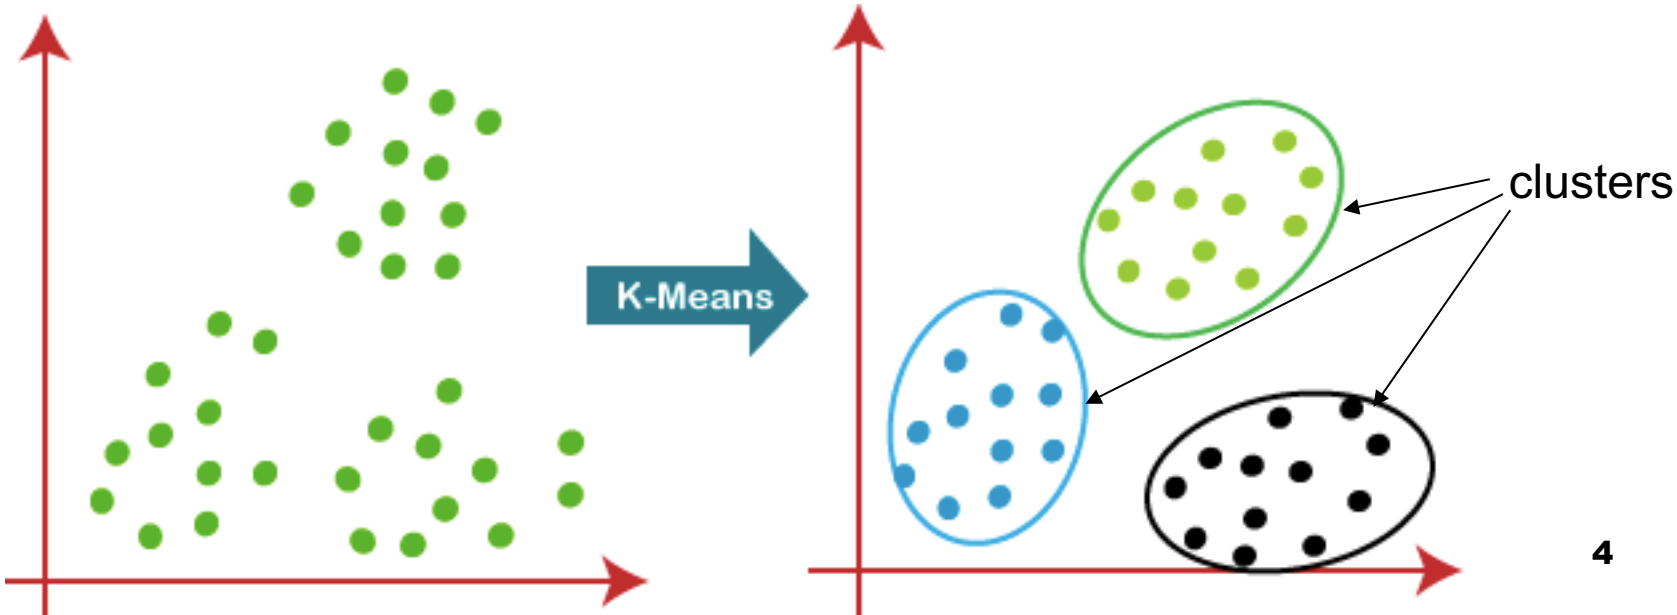

Plan

- Définition
- Champs d’application de K-Means
- Comment fonctionne le K-Means ?
- Comment choisir la valeur de "K" dans l’algorithme K-Means ?
- Les avantages et inconvénients de K-Means
- Fonction sur sklearn

Définition

- K-Means (K-moyennes) est un algorithme **itératif** qui divise un ensemble de **données non étiquetés** en K clusters (groupes) différents de telle sorte que chaque échantillon de cet ensemble n'appartient qu'à un seul cluster (groupe) ayant des propriétés similaires.
- K-Means permet de regrouper les données en différents groupes et cela constitue un moyen pratique pour découvrir les catégories de groupes dans l'ensemble de données non étiquetées.

Définition (Suite)

- Il s'agit d'un algorithme basé sur le centroïde, où chaque centroïde est associé à un cluster.
- L'objectif principal de l'algorithme K-Means est minimiser la distance entre les points de données et leurs centroïdes correspondants.

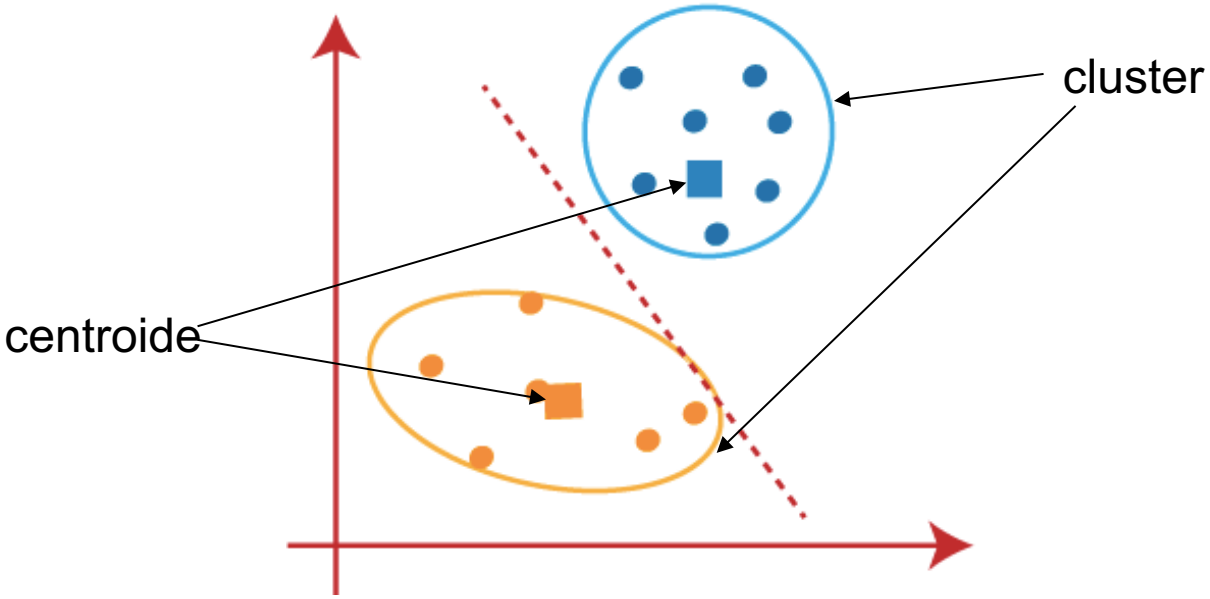

Définition (Suite)

- L'algorithme prend l'ensemble de données non étiquetés en entrée et le divise en nombre K de clusters et répète le processus jusqu'à ce qu'il ne trouve pas de meilleurs clusters pour chaque échantillon.
- La valeur de K (nombre de clusters) doit être prédéterminée dans l'algorithme K-Means. Nous allons voir après comment choisir la valeur de K.

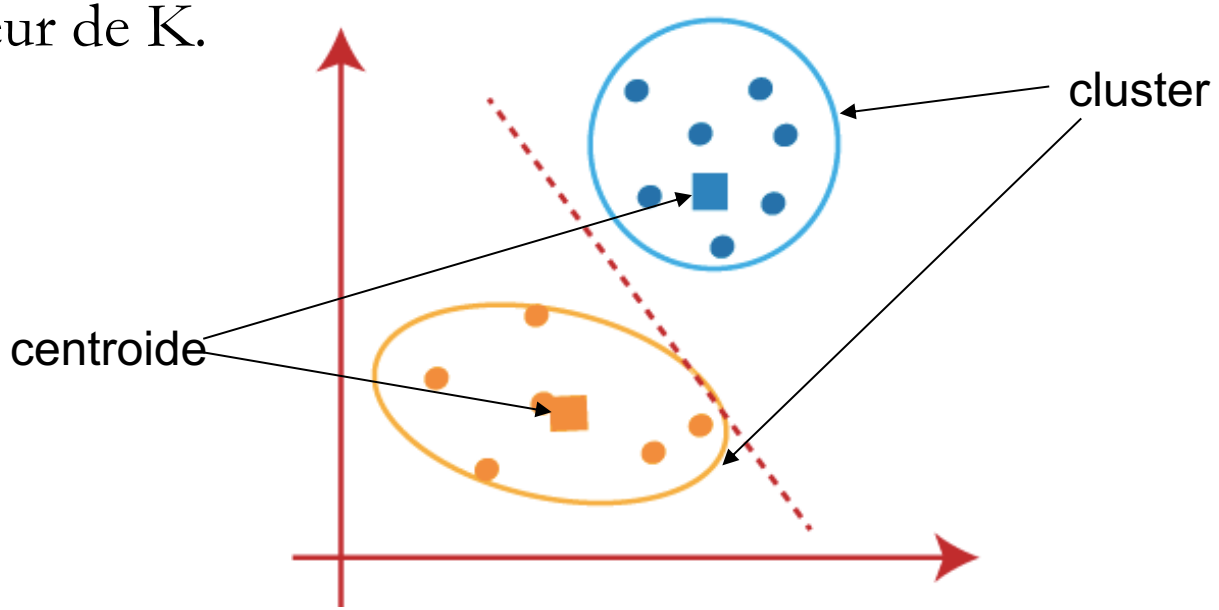

Définition (Suite)

- L'algorithme K-Means effectue principalement deux tâches :
  - Détermine, par un processus itératif, la meilleure valeur de K, qui représente les points centraux ou centroïdes.
  - Attribue chaque échantillon/point de données dans le dataset à son centroïde K le plus proche. Les points de données proches du centroïde K particulier créent un cluster.
- Par conséquent, chaque cluster a des échantillons/points de données qui ont des caractéristiques communes, et il est éloigné des autres clusters.

Définition (Suite)

- Le schéma ci-dessous explique le fonctionnement de l'algorithme de clustering K-means :

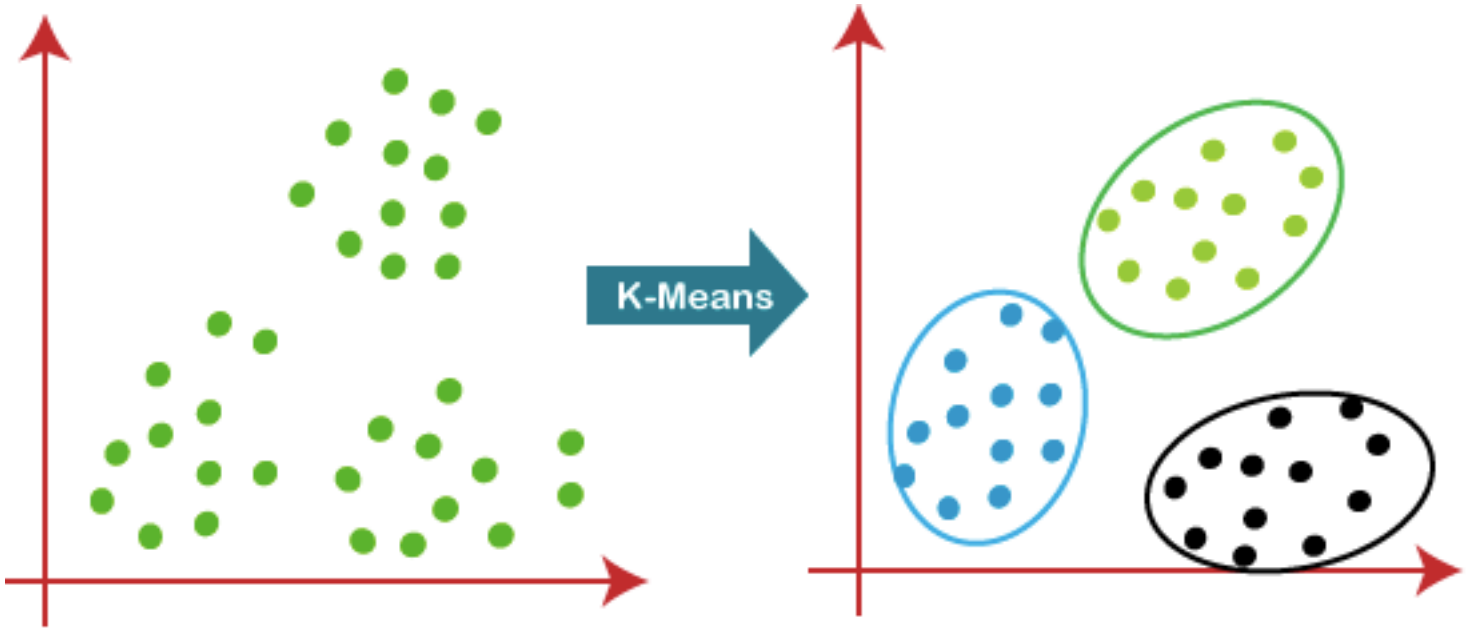

Champs d'application de K-Means

- K-means est un algorithme polyvalent et simple d'utilisation. Le K-means peut être utilisé dans divers domaines où il s'agit de regrouper des données similaires en clusters.
- **Marketing et segmentation de clients:** K-means est souvent utilisé pour regrouper les clients ayant des comportements d'achat similaires. Cela permet aux sociétés d'adapter leurs stratégies marketing en proposant des offres et des campagnes plus ciblées.

https://www.intelligence-artificielle-school.com/ecole/technologies/k-means-algorithme/

Champs d'application de K-Means (Suite)

- **Systèmes de recommandation:** Le K-means peut être utilisé dans les systèmes de recommandation pour regrouper les produits ou les utilisateurs ayant des préférences similaires pour proposer des recommandations personnalisées. Prenons l'exemple des plateformes de streaming video (NetFlix par exemple) qui recommandent les mêmes films aux utilisateurs ayant des préférences similaires. Aussi, les réseaux sociaux utilisent les algorithms de clustering pour regrouper les utilisateurs en fonction de leurs intérêts et leurs interactions. Cela leur permet de personnaliser les flux d'actualités et les suggestions de connexions.

https://www.intelligence-artificielle-school.com/ecole/technologies/k-means-algorithme/

Champs d'application de K-Means (Suite)

- **Secteur médical:** Le K-means est employé dans la recherche médicale pour classifier les données génomiques ou de profilage (créer des profiles) de protéines. Aussi, il peut être utilisé en imagerie médicale pour le partitionnement d'images en différents tissus ou structures anatomiques.
- **Domaine bancaire et financier:** En banque, le K-means peut être utilisé pour identifier des schémas de transactions inhabituels et ainsi détecter les fraudes. La segmentation de clients va permettre d'adapter les propositions de services financiers en fonction des besoins identifiés.

Comment fonctionne K-Means?

- Le fonctionnement de l'algorithme K-Means est expliqué dans les étapes ci-dessous :
- **Étape 1 :** Choisir le nombre K correspondant au nombre de clusters.
- **Étape 2 :** Sélectionner aléatoirement les points K ou centroïdes. Ils peuvent être différents des points de l'ensemble de données d'entrée.
- **Étape 3 :** Attribuer chaque échantillon/point de données à son centroïde le plus proche pour former les K clusters.
- **Étape 4 :** Calculer les coordonnées du centre du cluster et déplacer le centroïde de chaque cluster à ce centre, ou bien sélectionner un nouveau centroide.
- **Étape 5 :** Répéter la troisième étape, càd réaffecter chaque échantillon/point de données au nouveau centroïde le plus proche.
- **Étape 6 :** Si une réaffectation se produit, passez à l'Etape 4, sinon c'est terminé et le modèle est prêt.

Comment fonctionne K-Means? (Suite)

- Nous allons maintenant essayer de comprendre les étapes précédentes via un exemple.
- Supposons que nous avons deux attributs M1 et M2. Le diagramme de dispersion sur les axes x et y de ces deux attributs est donné ci-dessous :

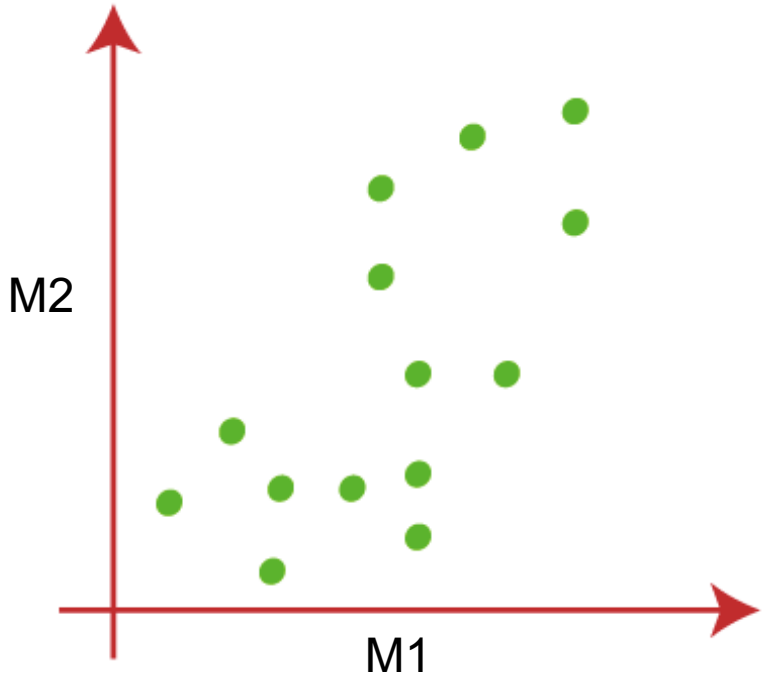

Comment fonctionne K-Means? (Suite)

- Prenons le nombre K de clusters, par exemple K = 2. Cela signifie que nous allons essayer de regrouper l'ensemble de données en deux groupes différents.

Comment fonctionne K-Means? (Suite)

- Nous devons choisir des points K ou des centroïdes pour former les clusters. Ces centroïdes peuvent être soit des points apparenants à l'ensemble de données, soit des points différents.
- Sur l'exemple ci-dessous, nous sélectionnons deux centroïdes (carraux) ne faisant pas partie de l'ensemble de données.

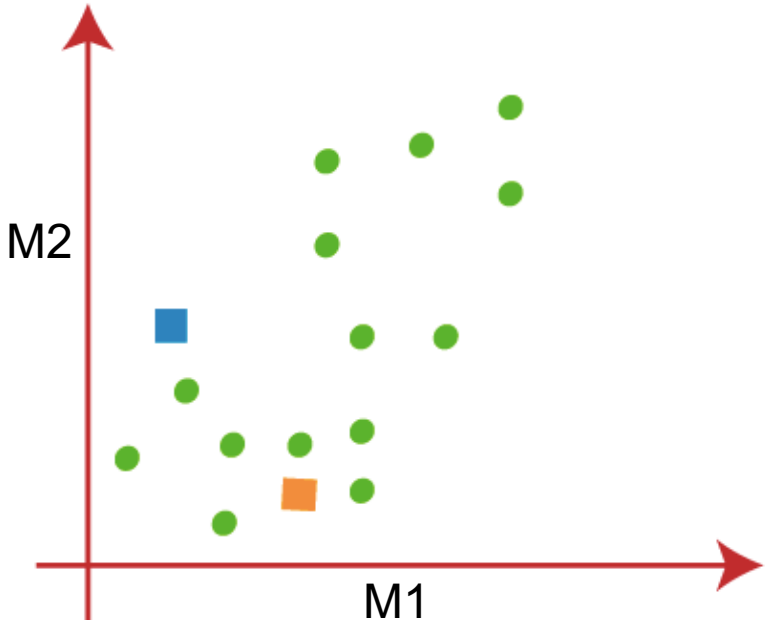

Comment fonctionne K-Means? (Suite)

- Nous allons maintenant attribuer chaque point de données du nuage de points (ensemble de données) à son point K ou centroïde le plus proche en calculant la distance entre deux points.
- Nous allons donc tracer une médiane entre les deux centroïdes comme sur l'image ci-dessous :

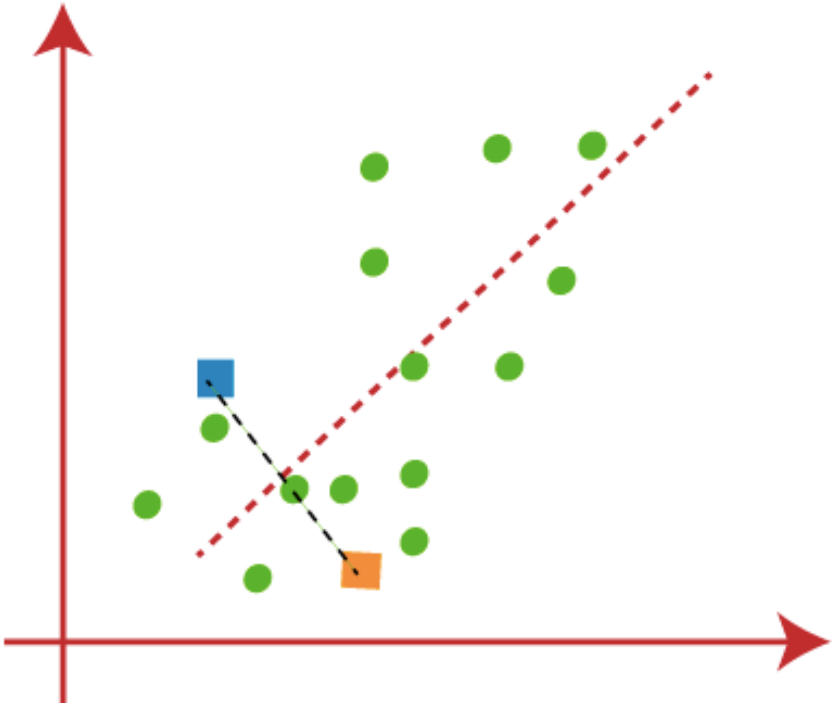

La médiane

- En théorie des probabilités et en statistiques, la médiane est une valeur qui sépare la moitié inférieure et la moitié supérieure des termes d'une série statistique quantitative ordonnée ou d'une variable aléatoire réelle. On peut la définir aussi pour une variable ordinale.

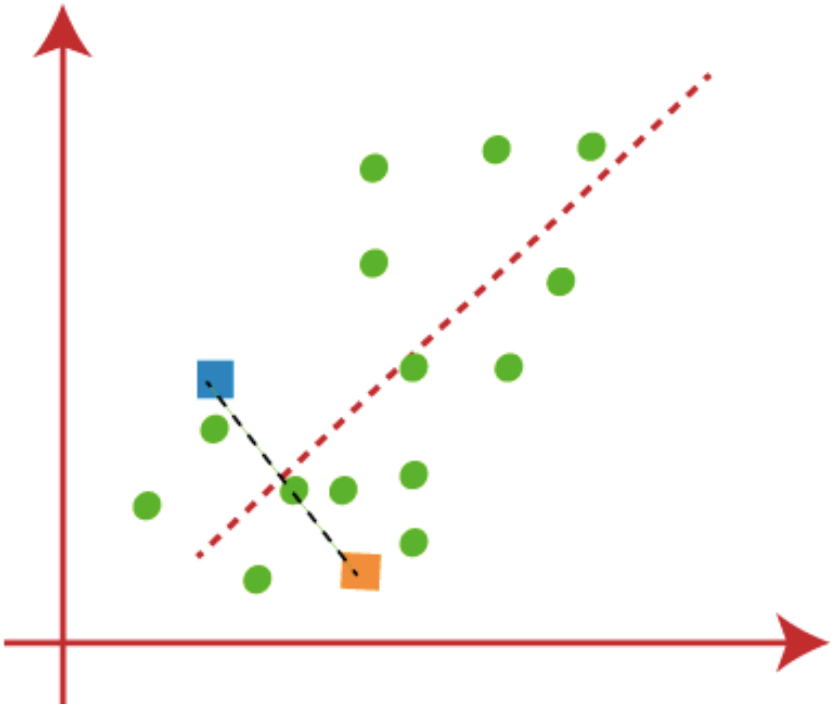

https://fr.wikipedia.org/wiki/M%C3%A9diane_(statistiques)

Comment fonctionne K-Means? (Suite)

- D'après l'image ci-dessous (à gauche), il est clair que les points du côté gauche de la ligne sont proches de K1 ou du centroïde bleu, et les points à droite de la ligne sont proches du centroïde orange.
- Colorions-les en bleu et orange pour une visualisation claire (image à droite).

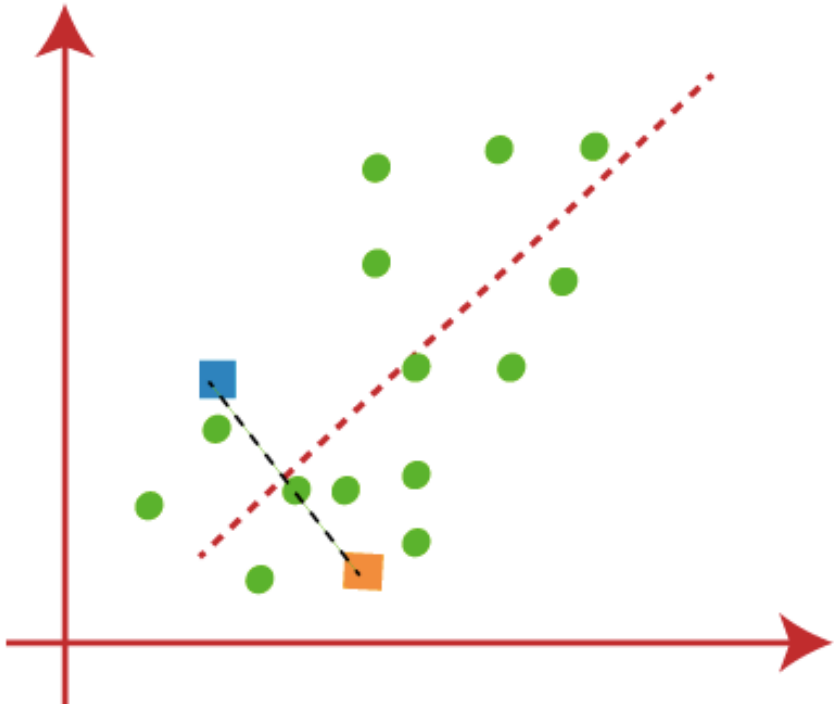

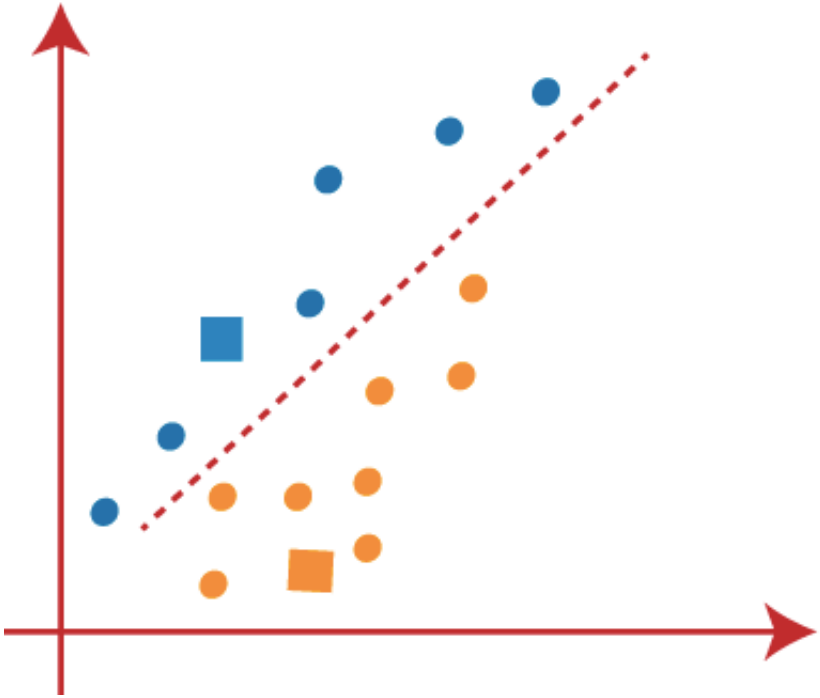

Comment fonctionne K-Means? (Suite)

- Comme nous devons trouver le centroïde le plus proche à chaque échantillon, nous allons donc répéter le processus en choisissant un nouveau centroïde pour chaque cluster.
- Pour retrouver les nouveaux centroïdes, nous calculerons les centres de gravité des clusters et nous déplaçons les centroïdes, comme illustré ci-dessous :

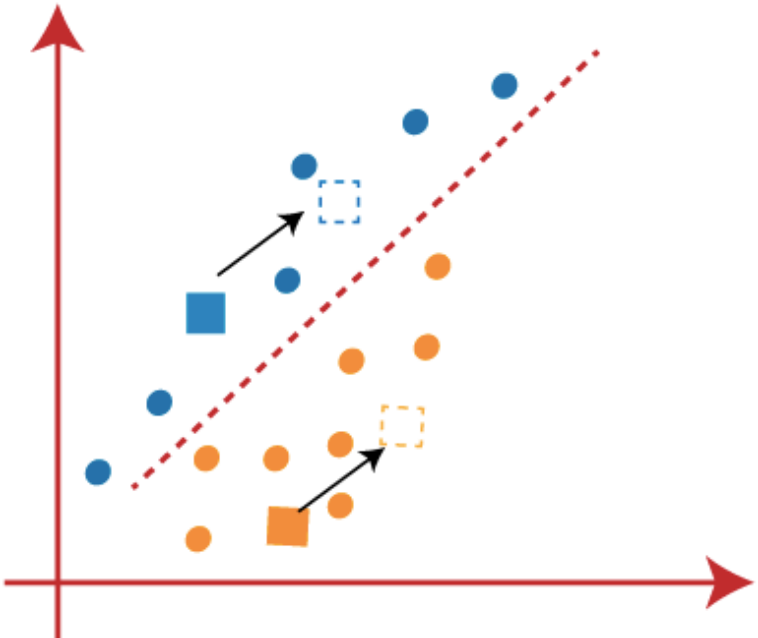

Comment fonctionne K-Means? (Suite)

- Ensuite, nous attribuerons chaque point de l'ensemble de données à son nouveau centroïde le plus proche. Pour cela, nous allons répéter le même processus de recherche d'une ligne médiane. La médiane sera comme illustrée sur l'image ci-dessous :

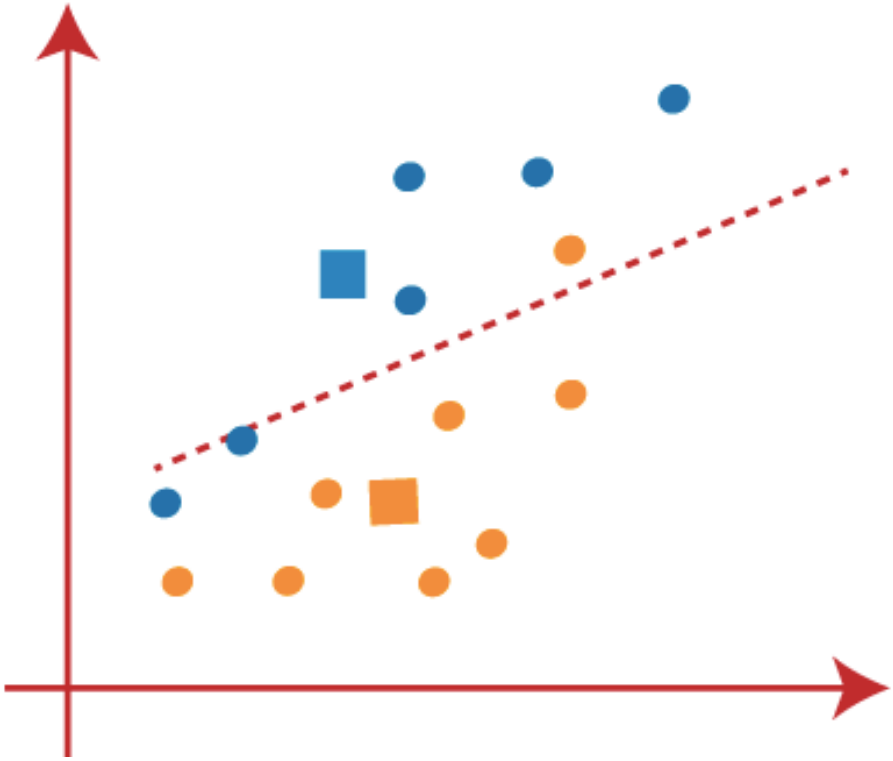

Comment fonctionne K-Means? (Suite)

- Sur l'image ci-dessus, nous pouvons voir qu'un point orange se trouve sur le côté gauche de la ligne et que deux points bleus se trouvent à droite de la ligne. Ainsi, ces trois points seront affectés aux nouveaux centroïdes.

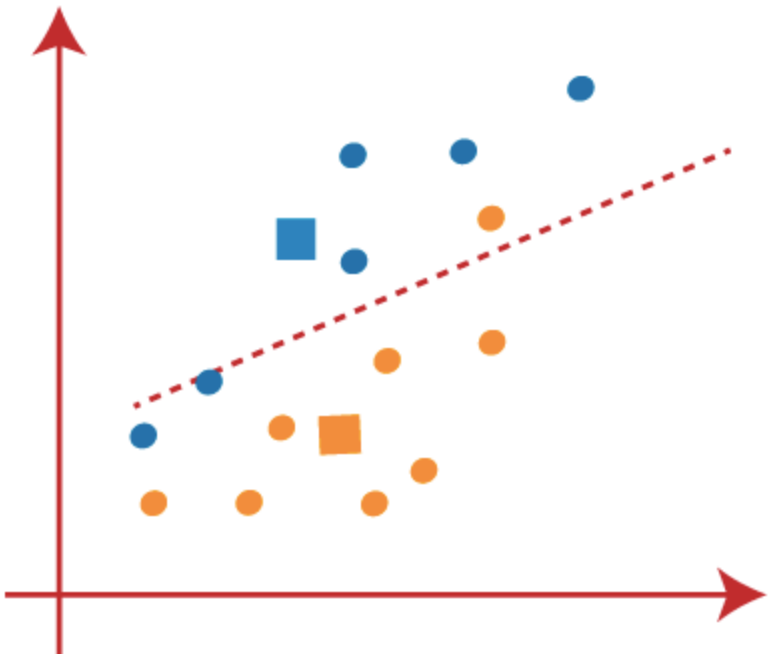

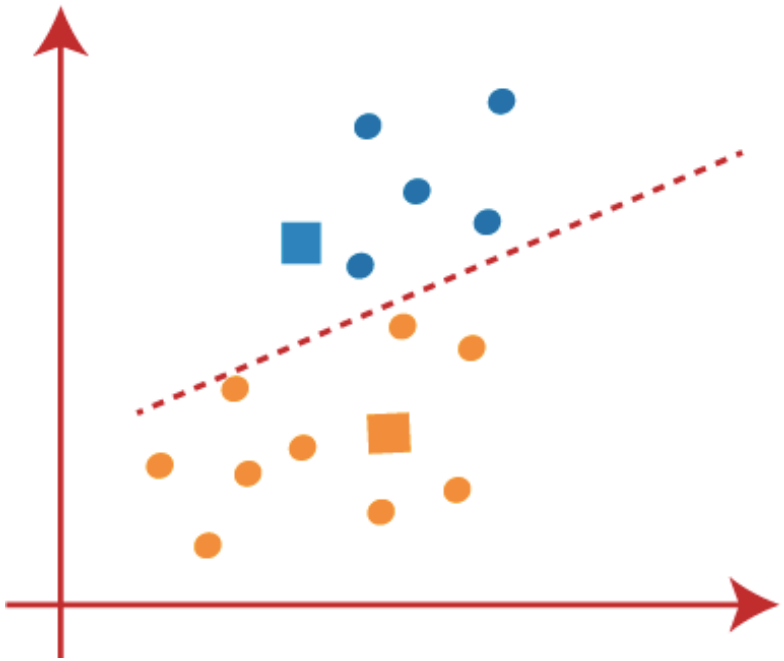

Comment fonctionne K-Means? (Suite)

- Au fur et à mesure qu'une réaffectation a eu lieu, nous passerons à nouveau à l'Etape 4, qui consiste à trouver de nouveaux centroïdes ou points K.
- Nous allons répéter le processus pour trouver le centre de gravité des clusters, comme indiqué dans l'image ci-dessous :

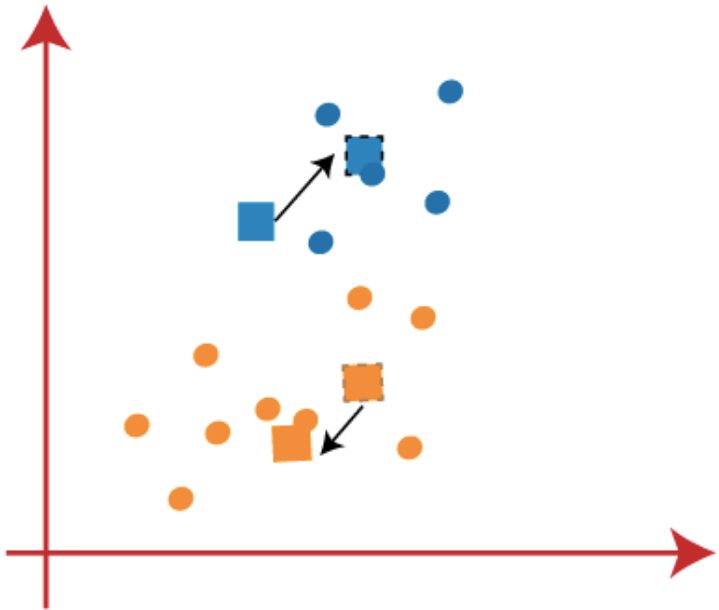

Comment fonctionne K-Means? (Suite)

- Au fur et à mesure que nous obtenons de nouveaux centroïdes, nous allons à nouveau tracer la ligne médiane et réaffecter les points de données. Ainsi, l'image sera :

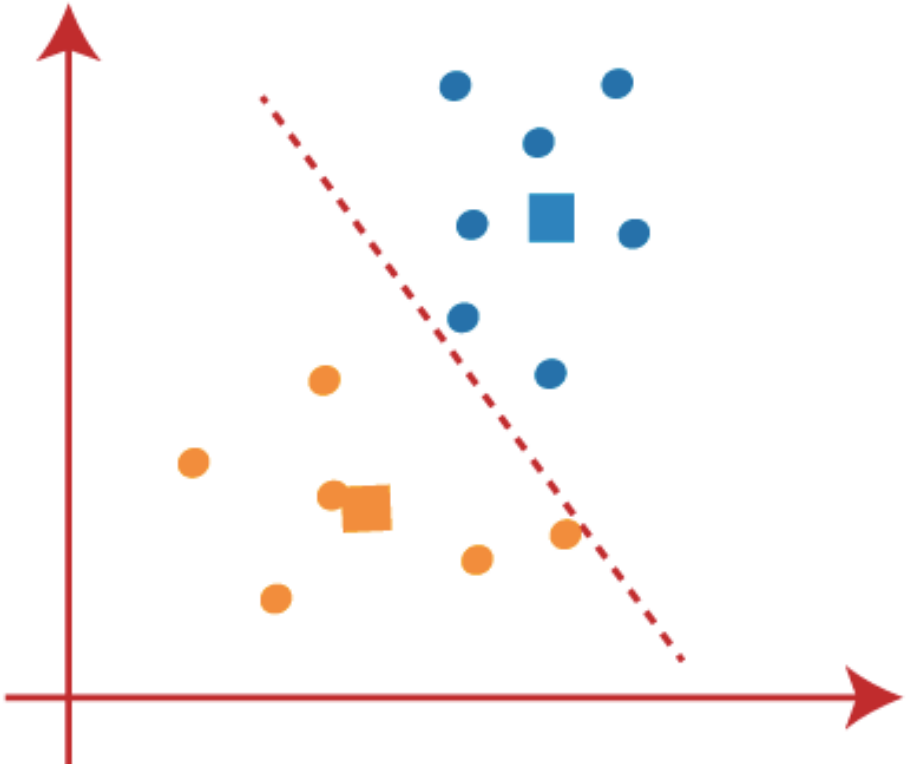

Comment fonctionne K-Means? (Suite)

- Nous pouvons voir sur l'image ci-dessous qu'il n'y a pas de points de données différents de chaque côté de la ligne, ce qui signifie que notre modèle est formé.

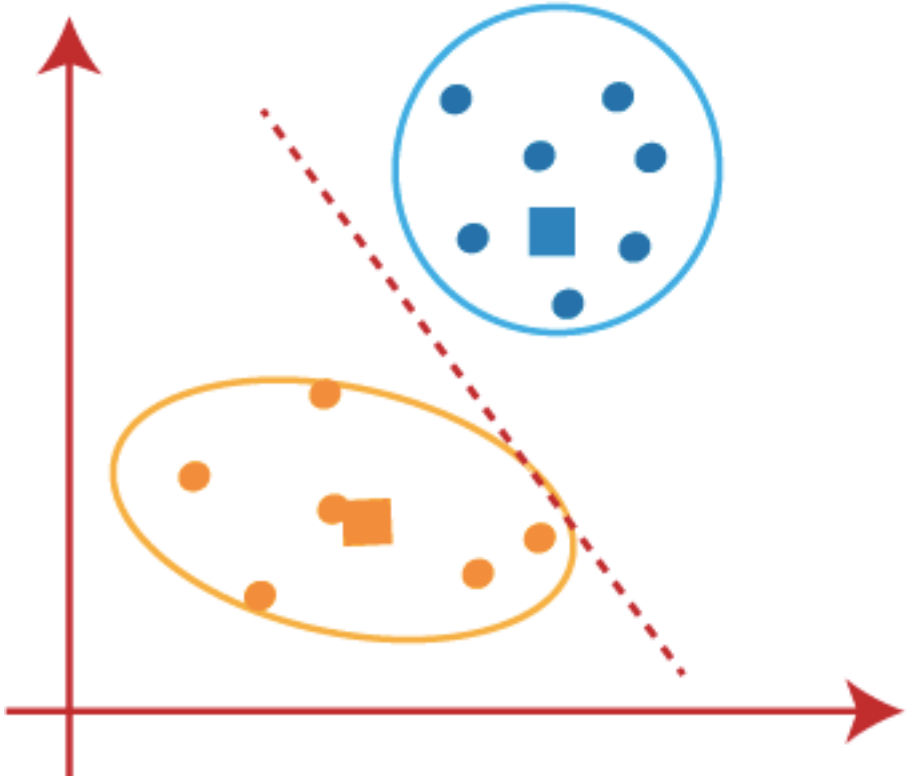

Comment fonctionne K-Means? (Suite)

- Comme notre modèle est prêt, nous pouvons maintenant supprimer les centroïdes supposés, et les deux clusters finaux seront comme indiqué dans l'image ci-dessous :

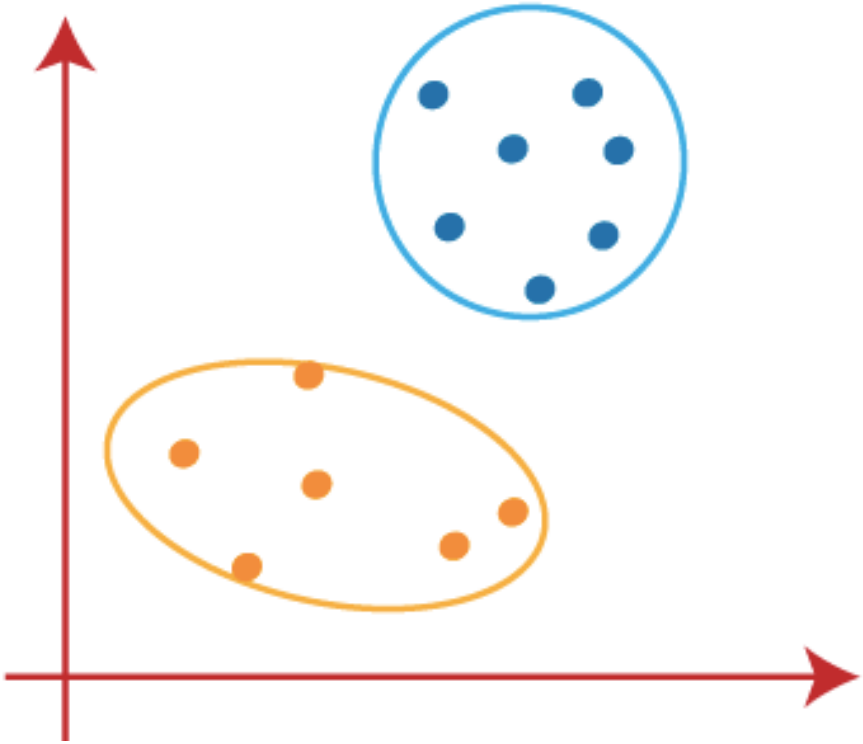

Comment fonctionne K-Means? (Suite)

Détails de calcul :

- Prenons le dataset constitué des points suivants:

A1(2, 10), A2(2, 5), A3(8, 4), B1(5, 8), B2(7, 5), B3(6, 4), C1(1, 2), C2(4, 9)

- On souhaite regrouper ces points en 3 clusters en utilisant la distance Euclidienne entre les points.

- Initialement, nous supposons que les points A1, B1 et C1 sont les centroïdes des 3 clusters respectivement.

https://www.youtube.com/watch?v=KzJORp8bgqs&pp=ygUTay1tZWFucyAzIGNsdXN0ZXJzIA%3D%3D

Comment fonctionne K-Means? (Suite)

- Nous allons calculer la distance euclidienne qui sépare chacun des centroïdes de chaque point du dataset.
- Remplir les 3 premières colonnes du tableau ci-dessous en utilisant la formule de calcul de la distance euclidienne:

Initial Centroids:
A1: (2, 10)
B1: (5, 8)
C1: (1, 2)

Data Points			Distance to						Cluster	New Cluster
			2	10	5	8	1	2		
A1	2	10								
A2	2	5								
A3	8	4								
B1	5	8								
B2	7	5								
B3	6	4								
C1	1	2								
C2	4	9								

$$d(p_1, p_2) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

Comment fonctionne K-Means? (Suite)

- Voila les résultats de calculs:

Initial Centroids:
A1: (2, 10)
B1: (5, 8)
C1: (1, 2)

Data Points			Distance to						Cluster	New Cluster
			2	10	5	8	1	2		
A1	2	10	0.00		3.61		8.06			
A2	2	5	5.00		4.24		3.16			
A3	8	4	8.49		5.00		7.28			
B1	5	8	3.61		0.00		7.21			
B2	7	5	7.07		3.61		6.71			
B3	6	4	7.21		4.12		5.39			
C1	1	2	8.06		7.21		0.00			
C2	4	9	2.24		1.41		7.62			

- Ensuite, nous recherchons la distance minimale qui sépare chaque point du dataset des 3 centroides et on affecte le point au cluster ayant la distance minimale.

Comment fonctionne K-Means? (Suite)

- Voila les clusters auxquels appartient chaque point du dataset:

Initial Centroids:
A1: (2, 10)
B1: (5, 8)
C1: (1, 2)

Data Points			Distance to			Cluster	New Cluster
			2 10	5 8	1 2		
A1	2	10	0.00	3.61	8.06	1	
A2	2	5	5.00	4.24	3.16	3	
A3	8	4	8.49	5.00	7.28	2	
B1	5	8	3.61	0.00	7.21	2	
B2	7	5	7.07	3.61	6.71	2	
B3	6	4	7.21	4.12	5.39	2	
C1	1	2	8.06	7.21	0.00	3	
C2	4	9	2.24	1.41	7.62	2	

$$d(p_1, p_2) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

Comment fonctionne K-Means? (Suite)

- Nous recalculons les nouveaux centroides par la moyenne des coordonnées des points appartenant à chaque centroide.

Data Points			Distance to						Cluster	New Cluster
			2	10	5	8	1	2		
A1	2	10	0.00		3.61		8.06		1	
A2	2	5	5.00		4.24		3.16		3	
A3	8	4	8.49		5.00		7.28		2	
B1	5	8	3.61		0.00		7.21		2	
B2	7	5	7.07		3.61		6.71		2	
B3	6	4	7.21		4.12		5.39		2	
C1	1	2	8.06		7.21		0.00		3	
C2	4	9	2.24		1.41		7.62		2	

- Donner les coordonnées des nouveaux centroides.

Comment fonctionne K-Means? (Suite)

- Voila les nouveaux centroides: A1(2, 10), B(6,6), et C(1.5, 3.5)

Data Points			Distance to						Cluster	New Cluster
			2	10	5	8	1	2		
A1	2	10	0.00		3.61		8.06		1	
A2	2	5	5.00		4.24		3.16		3	
A3	8	4	8.49		5.00		7.28		2	
B1	5	8	3.61		0.00		7.21		2	
B2	7	5	7.07		3.61		6.71		2	
B3	6	4	7.21		4.12		5.39		2	
C1	1	2	8.06		7.21		0.00		3	
C2	4	9	2.24		1.41		7.62		2	

Comment fonctionne K-Means? (Suite)

- Calcul de la distance entre chaque point du datatset et les nouveaux centroides.

Current Centroids:
A1(2, 10)
B(6, 6)
C(1.5, 3.5)

Data Points			Distance to						Cluster	New Cluster
			2	10	6	6	1.5	1.5		
A1	2	10							1	
A2	2	5							3	
A3	8	4							2	
B1	5	8							2	
B2	7	5							2	
B3	6	4							2	
C1	1	2							3	
C2	4	9							2	

$$d(p_1, p_2) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

Comment fonctionne K-Means? (Suite)

- Voila les distances entre chaque points du dataset et les 3 centroides:

Current Centroids:
A1(2, 10)
B(6, 6)
C(1.5, 3.5)

Data Points			Distance to						Cluster	New Cluster
			2	10	6	6	1.5	1.5		
A1	2	10	0.00		5.66		6.52		1	
A2	2	5	5.00		4.12		1.58		3	
A3	8	4	8.49		2.83		6.52		2	
B1	5	8	3.61		2.24		5.70		2	
B2	7	5	7.07		1.41		5.70		2	
B3	6	4	7.21		2.00		4.53		2	
C1	1	2	8.06		6.40		1.58		3	
C2	4	9	2.24		3.61		6.04		2	

- Après, nous recherchons la distance minimale qui sépare chaque point du dataset des 3 centroides et on affecte le point au nouveau cluster ayant la distance minimale.

Comment fonctionne K-Means? (Suite)

- Voila les clusters auxquels appartient chaque point du dataset (en rouge).
- Nous remarquons que le point C2 a changé de cluster → Recalculer les nouveaux les centroides.

Current Centroids:
A1(2, 10)
B(6, 6)
C(1.5, 3.5)

Data Points			Distance to						Cluster	New Cluster
			2	10	6	6	1.5	1.5		
A1	2	10	0.00		5.66		6.52		1	1
A2	2	5	5.00		4.12		1.58		3	3
A3	8	4	8.49		2.83		6.52		2	2
B1	5	8	3.61		2.24		5.70		2	2
B2	7	5	7.07		1.41		5.70		2	2
B3	6	4	7.21		2.00		4.53		2	2
C1	1	2	8.06		6.40		1.58		3	3
C2	4	9	2.24		3.61		6.04		2 →	1

- Calculer les nouveaux centroides.

Comment fonctionne K-Means? (Suite)

- Calcul des nouveaux centroides: A(3, 9.5), B(6.5, 5.25), et C(1.5, 3.5).

Current Centroids:
A1(2, 10)
B(6, 6)
C(1.5, 3.5)

New Centroids:
A(3, 9.5)
B(6.5, 5.25)
C(1.5, 3.5)

Data Points			Distance to						Cluster	New Cluster
			2	10	6	6	1.5	1.5		
A1	2	10	0.00		5.66		6.52		1	1
A2	2	5	5.00		4.12		1.58		3	3
A3	8	4	8.49		2.83		6.52		2	2
B1	5	8	3.61		2.24		5.70		2	2
B2	7	5	7.07		1.41		5.70		2	2
B3	6	4	7.21		2.00		4.53		2	2
C1	1	2	8.06		6.40		1.58		3	3
C2	4	9	2.24		3.61		6.04		2	1

$$d(p_1, p_2) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

- Calcul de la distance entre chaque point du datatset et les nouveaux centroides.

Comment fonctionne K-Means? (Suite)

- Voila le calcul de la distance entre chaque point du datatset et les nouveaux centroides:

Current Centroids:
A(3, 9.5)
B(6.5, 5.25)
C(1.5, 3.5)

Data Points			Distance to						Cluster	New Cluster
			3	9.5	6.5	5.25	1.5	3.5		
A1	2	10	1.12		6.54		6.52		1	
A2	2	5	4.61		4.51		1.58		3	
A3	8	4	7.43		1.95		6.52		2	
B1	5	8	2.50		3.13		5.70		2	
B2	7	5	6.02		0.56		5.70		2	
B3	6	4	6.26		1.35		4.53		2	
C1	1	2	7.76		6.39		1.58		3	
C2	4	9	1.12		4.51		6.04		1	

$$d(p_1, p_2) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

- Rechercher les nouveaux centroides de chaque point du dataset.

Comment fonctionne K-Means? (Suite)

- Après, nous recherchons la distance minimale qui sépare chaque point du dataset des 3 nouveaux centroides et on affecte le point au nouveau cluster ayant la distance minimale (en rouge).
- Nous remarquons que le point B1 a changé de cluster → Recalculer les nouveaux centroides.

Current Centroids:
A(3, 9.5)
B(6.5, 5.25)
C(1.5, 3.5)

Data Points			Distance to						Cluster	New Cluster
			3	9.5	6.5	5.25	1.5	3.5		
A1	2	10	1.12		6.54		6.52		1	1
A2	2	5	4.61		4.51		1.58		3	3
A3	8	4	7.43		1.95		6.52		2	2
B1	5	8	2.50		3.13		5.70		2	1
B2	7	5	6.02		0.56		5.70		2	2
B3	6	4	6.26		1.35		4.53		2	2
C1	1	2	7.76		6.39		1.58		3	3
C2	4	9	1.12		4.51		6.04		1	1

$$d(p_1, p_2) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

Comment fonctionne K-Means? (Suite)

- Calcul des 3 nouveaux centroides:

Current Centroids:
A(3, 9.5)
B(6.5, 5.25)
C(1.5, 3.5)

New Centroids:
A(3.67, 9)
B(7, 4.33)
C(1.5, 3.5)

Data Points			Distance to						Cluster	New Cluster
			3	9.5	6.5	5.25	1.5	3.5		
A1	2	10	1.12		6.54		6.52		1	1
A2	2	5	4.61		4.51		1.58		3	3
A3	8	4	7.43		1.95		6.52		2	2
B1	5	8	2.50		3.13		5.70		2	1
B2	7	5	6.02		0.56		5.70		2	2
B3	6	4	6.26		1.35		4.53		2	2
C1	1	2	7.76		6.39		1.58		3	3
C2	4	9	1.12		4.51		6.04		1	1

$$d(p_1, p_2) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

- Calcul de la distance entre chaque point du datatset et les nouveaux centroides.

Comment fonctionne K-Means? (Suite)

- Voila le calcul de la distance entre chaque point du datatset et les nouveaux centroides.

Current Centroids:
A(3.67, 9)
B(7, 4.33)
C(1.5, 3.5)

Data Points			Distance to			Cluster	New Cluster
			3.67 9	7 4.33	1.5 3.5		
A1	2	10	1.94	7.56	6.52	1	
A2	2	5	4.33	5.04	1.58	3	
A3	8	4	6.62	1.05	6.52	2	
B1	5	8	1.67	4.18	5.70	1	
B2	7	5	5.21	0.67	5.70	2	
B3	6	4	5.52	1.05	4.53	2	
C1	1	2	7.49	6.44	1.58	3	
C2	4	9	0.33	5.55	6.04	1	

$$d(p_1, p_2) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

- Rechercher les nouveaux centroides.

Comment fonctionne K-Means? (Suite)

- Après, nous recherchons la distance minimale qui sépare chaque point du dataset des 3 nouveaux centroides et on affecte le point au nouveau cluster ayant la distance minimale (en vert).
- Nous remarquons que tous les points n'ont pas changé de cluster → Arrêt des calculs et le modèle est formé.

Current Centroids:
A(3.67, 9)
B(7, 4.33)
C(1.5, 3.5)

Data Points			Distance to						Cluster	New Cluster
			3.67	9	7	4.33	1.5	3.5		
A1	2	10	1.94		7.56		6.52		1	1
A2	2	5	4.33		5.04		1.58		3	3
A3	8	4	6.62		1.05		6.52		2	2
B1	5	8	1.67		4.18		5.70		1	1
B2	7	5	5.21		0.67		5.70		2	2
B3	6	4	5.52		1.05		4.53		2	2
C1	1	2	7.49		6.44		1.58		3	3
C2	4	9	0.33		5.55		6.04		1	1

$$d(p_1, p_2) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

Comment choisir la valeur de "K" dans l'algorithme K-Means ?

- Les performances de l'algorithme K-Means clustering dépendent des clusters qu'il forme. Ainsi, le choix du nombre optimal de clusters est une tâche importante.
- Il existe différentes façons de trouver le nombre optimal de clusters, tells que la méthode Elbow et la méthode Silhouette. Nous allons présenter la **méthode Elbow** (coude) qui est la méthode la plus utilisé pour trouver le nombre de clusters ou la valeur de K.

Comment choisir la valeur de "K" dans l'algorithme K-Means ? (Suite)

- La méthode Elbow est l'une des moyens les plus populaires pour trouver le nombre optimal de clusters K.
- Cette méthode utilise le concept de valeur WCSS (Within Cluster Sum of Squares) qui définit les variations totales au sein d'un cluster. La formule de calcul de la valeur WCSS (pour 3 clusters par exemple) est donnée ci-dessous :
- $WCSS = \sum_{P_i in\ Cluster1} distance\,(P_i, C_1)^2 + \sum_{P_i in\ Cluster2} distance\,(P_i, C_2)^2 + \sum_{P_i in\ Cluster3} distance\,(P_i, C_3)^2$
- Avec $\sum_{P_i in\ Cluster1} distance\,(P_i, C_1)^2$, la somme au carré des distances entre chaque point de données P_i et son centroïde C_1 dans le $Cluster1$. Même chose pour les deux autres termes.

Comment choisir la valeur de "K" dans l'algorithme K-Means? (Suite)

- Pour mesurer la distance entre les points de données et le centroïde, nous pouvons utiliser n'importe quelle méthode telle que la distance euclidienne ou la distance de Manhattan, ou autre.
- La méthode Elbow suit les étapes ci-dessous pour trouver la valeur optimale de K :
  - Exécuter l'algorithme K-Means clustering sur l'ensemble de données avec différentes valeurs de K (plage de 1 à 10).
  - Pour chaque valeur de K, calculer la valeur WCSS.
  - Tracer une courbe en fonction des WCSS et K correspondantes.
  - Le point de courbure aigu où un point du tracé ressemble à un coude est considéré comme la meilleure valeur de K.

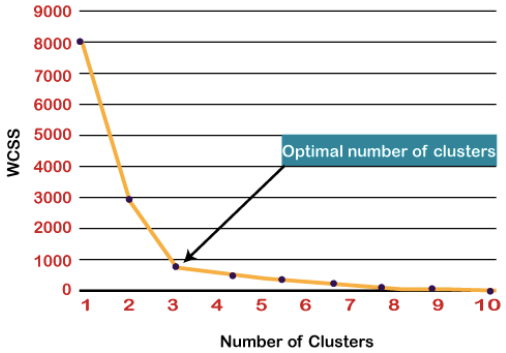

Comment choisir la valeur de "K" dans l'algorithme K-Means? (Suite)

- On remarque sur ce graphique la forme d'un bras où le point le plus haut représente l'épaule et le point où K=9 ou 10 représente la main.
- Le nombre optimal de clusters est le point représentant le coude (elbow).
- Le coude peut être représenté par K=3 et c'est le nombre optimal de clusters dans cet exemple.
- Généralement, le point du coude est celui du nombre de clusters à partir duquel la variance ne se réduit plus de manière significative.
- En effet, la "chute" de la courbe de variance entre K=1 et 3 est significativement plus grande que celle entre K=5 et 10.

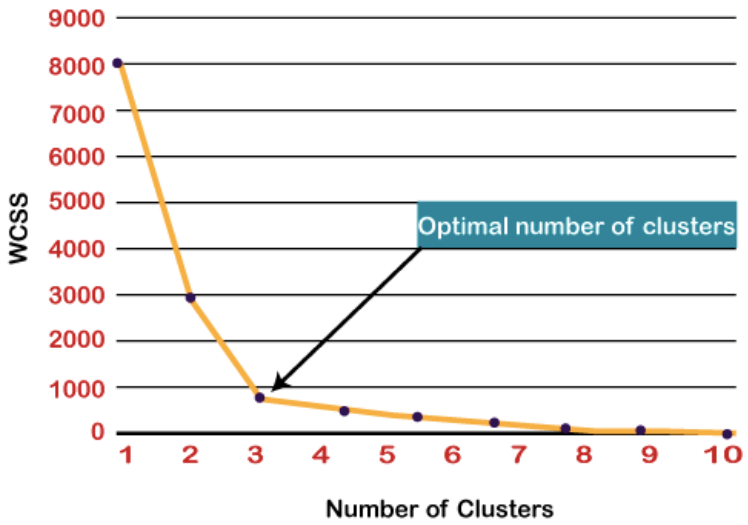

Comment choisir la valeur de "K" dans l'algorithme K-Means? (Suite)

- Remarque : Nous pouvons choisir un nombre de clusters égale aux nombres de points de données, dans ce cas, la valeur de WCSS devient zéro, et ce sera le point final du clustering.

Avantages et inconvenients de K-Means

- L'algorithme K-Means possède bien des avantages, mais aussi des inconvénients.
- On peut citer les avantages suivants :
  - Relativement simple à mettre en oeuvre.
  - Méthode de calcul rapide.
  - Applicable aux données de grandes tailles, et aussi à tout type de données mêmes textuelles, en choisissant une bonne notion de distance.
  - Garantit la convergence.
  - Ses résultats sont plus faciles à interpréter, car il génère des descriptions de cluster simplifiées, pour une meilleure compréhension des données.
  - S'adapte facilement aux nouveaux exemples.

https://www.intelligence-artificielle-school.com/ecole/technologies/k-means-algorithme/

https://www.editions-eni.fr/open/mediabook.aspx?idR=2eab2a21f25c8d99d6d444cbccbd3857

Avantages et inconvenients de K-Means

- Fonctionne particulièrement bien avec des clusters sphériques, car il suppose que chaque cluster a cette forme.
- Se généralise aux clusters de différentes formes et tailles, tels que les clusters elliptiques.

Sphère

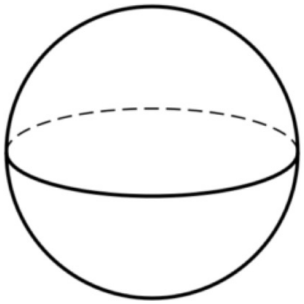

Ellipse

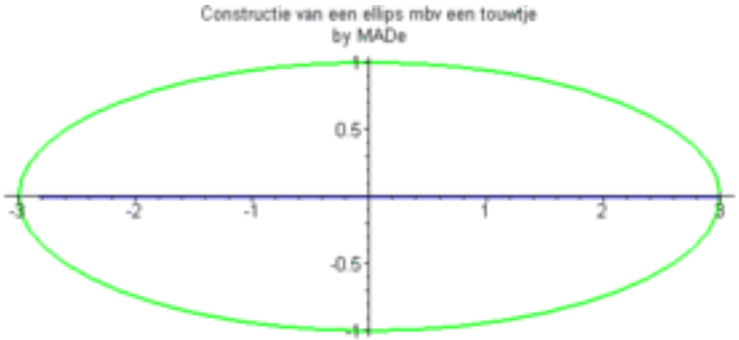

https://fr.wikipedia.org/wiki/Ellipse_%28math%C3%A9matiques%29

https://www.intelligence-artificielle-school.com/ecole/technologies/k-means-algorithme/

Avantages et inconvenients de K-Means (Suite)

- Parmi les inconvénients majeurs de l'algorithme K-Means, il y'a :
  - Le nombre de clusters K doit être défini à l'avance pour obtenir des résultats efficaces.
  - Le résultat final du clustering dépend du choix des centroïdes initiaux.
  - L'utilisation de points de départ aléatoires peut produire des résultats différents, et entraîner des incohérences.
  - Il est sensible à l'ordre des données, ce qui peut influencer les résultats du clustering.
  - Les centroïdes des clusters, mis à part des centres initiaux dans certains cas, sont des objets inexistants puisqu'ils correspondent à des moyennes calculées sur un sous-ensemble d'observations à chaque itération.
  - Une forte influence des valeurs aberrantes sur les résultats.
  - Il donne des résultats médiocres pour les données qui ne sont pas linéairement séparables.

https://www.intelligence-artificielle-school.com/ecole/technologies/k-means-algorithme/

https://www.editions-eni.fr/open/mediabook.aspx?idR=2eab2a21f25c8d99d6d444cbccbd3857

Fonction sur sklearn

- ***class*** **sklearn.cluster.KMeans(*n_clusters*=*8*, ***, *init*='*k-means++*', *n_init*='*auto*', *max_iter*=*300*, *tol*=*0.0001*, *verbose*=*0*, *random_state*=*None*, *copy_x*=*True*, *algorithm*='*lloyd*')**
- K-Means clustering.

- **n_clusters** *int, default=8* The number of clusters to form as well as the number of centroids to generate.

https://scikit-learn.org/1.5/modules/generated/sklearn.cluster.KMeans.html#

Fonction sur sklearn

- **init** {*'k-means++', 'random'*}, *callable or array-like of shape (n_clusters, n_features)*, default='k-means++'

  Method for initialization:

  - 'k-means++' : selects initial cluster centroids using sampling based on an empirical probability distribution of the points' contribution to the overall inertia. This technique speeds up convergence. The algorithm implemented is "greedy k-means++". It differs from the vanilla k-means++ by making several trials at each sampling step and choosing the best centroid among them.
  - 'random': choose n_clusters observations (rows) at random from data for the initial centroids.
  - If an array is passed, it should be of shape (n_clusters, n_features) and gives the initial centers.
  - If a callable is passed, it should take arguments X, n_clusters and a random state and return an initialization.

For more information about k-means++: https://en.wikipedia.org/wiki/K-means%2B%2B

Fonction sur sklearn (Suite)

- **n_init** *'auto' or int, default='auto'* Number of times the k-means algorithm is run with different centroid seeds. The final results is the best output of n_init consecutive runs in terms of inertia. Several runs are recommended for sparse high-dimensional problems.

When *n_init='auto'*, the number of runs depends on the value of init: 10 if using init='random' or init is a callable; 1 if using init='k-means++' or init is an array-like.

- **max_iter** *int, default=300* Maximum number of iterations of the k-means algorithm for a single run.
- **tol** *float, default=1e-4* Relative tolerance with regards to Frobenius norm of the difference in the cluster centers of two consecutive iterations to declare convergence.

For more information about Frobenius norm, visit this website:
https://www.sciencedirect.com/topics/mathematics/frobenius-norm#:~:text=The%20Frobenius%20norm%20requires%20that,the%20entries%20of%20a%20row.&text=%25%20Input%3A%20m%20%C3%97%20n%20matrix%20A.

Fonction sur sklearn (Suite)

- **Exemple:**
- With max_iter=2 and n_init=15, kmeans will choose initial centroids 15 times and move up to twice on each of the 15 runs.
- The default values are n_init=10 and max_iter=300. This means the initial centroids will be chosen 10 times, and each run will use up to 300 iterations. The best out of those 10 runs will be the final result.

Fonction sur sklearn (Suite)

- **verbose** *int, default=0* Verbosity mode.
- **random_state** *int, RandomState instance or None, default=None* Determines random number generation for centroid initialization. Use an int to make the randomness deterministic.
- **copy_x** *bool, default=True* When pre-computing distances it is more numerically accurate to center the data first. If copy_x is True (default), then the original data is not modified. If False, the original data is modified, and put back before the function returns, but small numerical differences may be introduced by subtracting and then adding the data mean. Note that if the original data is not C-contiguous, a copy will be made even if copy_x is False. If the original data is sparse, but not in CSR format, a copy will be made even if copy_x is False.

Fonction sur sklearn (Suite)

- **algorithm** {*"lloyd", "elkan"*}, *default="lloyd"* K-means algorithm to use. The classical EM-style algorithm is "lloyd". The "elkan" variation can be more efficient on some datasets with well-defined clusters, by using the triangle inequality. However it's more memory intensive due to the allocation of an extra array of shape (n_samples, n_clusters).